

CONSTRUCTION D'UN PIPELINE ETL & MACHINE LEARNING ORCHESTRÉ

Realise par:

Adam AMARA

Saad GAGA

Walid LABIED


Othmane LEMJID

Encadre par:

Youssef GAHI



SOMMAIRE

- 
- 1 Introduction
 - 2 Architecture Globale du Pipeline
 - 3 Extraction des Données – Airbyte
 - 4 Transformation – dbt
 - 5 Validation – Great Expectations
 - 6 Orchestration – Dagster
 - 7 Machine Learning – MLflow
 - 8 Dashboard – Metabase
 - 9 Conclusion
 - 10 Demo

INTRODUCTION


Ce projet présente la construction d'un pipeline automatisé pour collecter, transformer, valider et exploiter les données.

Il combine des outils modernes tels qu'Airbyte, dbt, Great Expectations, Dagster et MLflow.

L'objectif est de garantir une donnée fiable et d'automatiser tout le processus jusqu'à la modélisation et la visualisation.




ARCHITECTURE GLOBALE DU PIPELINE



EXTRACTION DES DONNÉES : AIRBYTE

RÔLE D'AIRBYTE

- Plateforme d'ingestion qui automatise la collecte des données depuis différentes sources.
- Supporte de nombreux connecteurs (CSV, API, bases SQL...).
- Permet des synchronisations programmées .




TRANSFORMATION : DBT

RÔLE DE DBT

- Nettoyer, transformer et structurer les données.
- Standardiser les colonnes et les types.
- Automatiser les modèles SQL sous forme de pipelines reproductibles.
- Générer la documentation et le lineage automatiquement.





VALIDATION DES DONNÉES : GREAT EXPECTATIONS

Rôle de Great Expectations

- Garantir la qualité et la fiabilité des données transformées.
- Définir des règles : valeurs non nulles, types corrects, montants ≥ 0 , etc.
- Générer des rapports de validation clairs (HTML).

Dans notre projet

- Deux suites de validation principales :
 - stg_sales_data_suite : contrôle des données brutes nettoyées.
 - fct_sales_suite : validation des montants, dates, quantités, prix...
- Exécution automatique après dbt via Dagster.


Résultat

- 100% des tests passés avec succès.
- Les rapports GX sont accessibles via le serveur dédié (port 8090).
- Données validées avant usage ML ou analytics

ORCHESTRATION – DAGSTER

RÔLE DE DAGSTER


- Dagster orchestre et automatise l'exécution des différentes étapes d'un pipeline de données.
- Il garantit que chaque tâche s'exécute dans le bon ordre, offre une interface pour suivre les runs et facilite la supervision et la fiabilité du workflow.



MODÉLISATION MACHINE LEARNING : MLFLOW

RÔLE DE MLFLOW

- Suivre, comparer et versionner les modèles ML.
- Enregistrer automatiquement :
 - paramètres,
 - métriques (RMSE, MAE),
 - artefacts (plots, modèles),
 - code source utilisé.
- Faciliter la sélection du meilleur modèle.




The screenshot displays the MLflow web interface. On the left, the 'Experiments' sidebar shows 'TimeSeries_Models_Training' selected. The main panel shows the details for this experiment, including a search bar with the query 'metrics.rmse < 1 and params.model = "tree"', filters for 'Time created', 'State: Active', and 'Datasets', and a '+ New run' button. Below this is a table with tabs for 'Table', 'Chart', 'Evaluation', and 'Experimental'. The 'Table' tab is active, showing a list of runs.


	Run Name	Created	Dataset	Duration	Source	Models
☐	XGBoost_NetSales	13 minutes ago	-	1.8min	train_all_...	-
☐	XGBoost_NetSales	8 hours ago	-	0.6s	train_all_...	-

VISUALISATION DES DONNÉES : METABASE

RÔLE DE METABASE

- Fournir des visualisations dynamiques facilitant la prise de décision.
- Construire des dashboards interactifs basés sur les données transformées.
- Permettre une exploration simple pour les utilisateurs non techniques.





CONCLUSION

Ce projet a permis de mettre en place un pipeline complet et automatisé allant de l'extraction des données jusqu'à la modélisation.

Grâce à Airbyte, dbt et Great Expectations, les données sont nettoyées, transformées et validées de manière fiable.

Dagster orchestre l'ensemble du processus tandis que MLflow assure le suivi et la comparaison des modèles.